



M5 Pro 또는 M5 Max 탑재 MacBook Pro 실제
제품사진 · Apple Newsroom 미디어 자산

종합 1위
Qwen3.5-122B-
A10B 4-bit
멀티모달·다국어·
에이전트 + 실측
가능한 속도

모델 저장소	69.6GB
32K 피크	76.4GB
명목 여유	51.6GB

614GB/s

공식 메모리 대역폭

63.9 tok/s

디코드 실측 중앙값

32K

권장 시작 컨텍스트

4-bit 품질이 실제 과제에서 부족할 때만 5-bit 84.9GB로 올립니다. 전체 메모리를 모델에 쓰지 않습니다.

한 모델이 아니라 역할별 3개 프로파일

**주력 · Qwen 122B 4-bit**

한국어·문서·이미지·에이전트

코딩 · Qwen Coder Next 6-bit

대형 코드베이스·CLI 에이전트

속도 · Qwen 35B A3B 4-bit

보조 모델·병렬 작업·빠른 응답

피하기 · 397B 1-bit / swap

적재 시연이지 실용 최적이지 않음

1. 32K 시작 → 2. 10개 과제 A/B → 3. 필요할 때만 확대

단일 슬롯·전원 연결 품질·프리필·디코드 5-bit·64K 순차 승격

SSD 2TB는 체크포인트 보관함입니다. 실행 순간에는 모델·KV·런타임·앱이 128GB 통합 메모리를 함께 씁니다.