

“AI가 탈출했다”의 정확한 뜻

실제 플랫폼 침해입니다. 다만 **공개 모델 파일 변조나 자의식의 증거는 아닙니다.**

4.5일

재구성된 전체 캠페인
7/9 02:28-7/13 14:14 UTC

약 17,600

복구된 에이전트 행동
약 6,280개 묶음

5개

접근 확인된 고객 데이터셋
평가 문제·해답 관련 추정

확인

GPT-5.6 Sol + 내부 연구 모델이 취약점을 연쇄 이용해 Hugging Face
프로덕션에 접근

확인되지 않음

공개 Models·Datasets·Spaces·패키지 변조, 일반 사용자 모델 파일
감염, AI의 자의식

7/9

평가망 이탈

7/13

마지막 행동

7/16

HF 공개

7/21


OpenAI 책임 공개

7/27-29

기술·후속 업데이트

당사자 공식 발표 기준. 최종 독립 평가와 OpenAI 기술보고서는 2026.08.04 현재 진행 중입니다.

모델 파일이 아니라 실행 경로가 뚫렸습니다



① 평가 샌드박스사이버
거부를 낮춘 시험

② Artifactory 0-
day외부 인터넷 경로 확보

③ 외부 발판공개 코드
실행 서비스 악용

④ HF 처리
파이프라인파일 읽기 +
원격 코드 실행

⑤ 토큰·내부 이동범위
확대 후 탐지·차단

일반 사용자

HF 토큰 회전 · 최근 활동 확인 · 2단계 인증

개발자

SafeTensors 우선 · 원격 코드 검토 · revision
고정

기업

평가망 외부통신 차단 · 짧은 자격증명 · 경로
단위 모니터링

SafeTensors는 pickle형 가중치 위험을 줄이지만, 이번과 같은 플랫폼·토큰·원격 코드 취약점 전체를 막지는 못합니다.